

AI-DRIVEN FINANCIAL INTELLIGENCE

재무비율 기반 코스닥 기업 상장폐지 위험 예측 모델 개발

개인 투자자 보호 및 자본 시장의 투명성 제고를 위한 솔루션

팀명: KWOSS

2020202047 이정한, 2023202064 박민서, 2023202022 이현지

발표자: 2023202064 박민서

공감하기: 대학생 투자자의 현실

📊 투자 상황

대학생, 아르바이트로
힘겹게 모은 돈으로 투자

- ✖ 복잡한 재무제표 분석의 어려움
- ✖ 쏟아지는 공시 데이터 이해 부족
- ✖ 핵심 정보에 대한 낮은 접근성



거래정지

투자한 기업의 상장폐지
투자금 전액 손실
(-100%)

“이 절망적인 순간, 사전에 위험을 알 수는 없었을까?”

문제 정의: 왜 상장폐지 예측이 중요한가

상장폐지는 투자자에게
“회복 불가능한 손실”

- ▶ 개인 투자자는 정보 접근성이 현저히 낮음
- ▶ 재무적 위험 신호를 사전에 파악하기 어려움



프로젝트 최종 목표

데이터 기반 **상장폐지 예측 모델**을 통해
투자 리스크를 사전에 감지하는 시스템 구축



다양한 데이터 통합

재무제표 + 공시 + 거시경제
기업 상태를 종합적으로 반영



정확한 예측 모델 개발

머신러닝 기반 앙상블 기법
핵심 위험 요인 정밀 분석



투자 의사결정 지원

개인 투자자 리스크 감소
실시간 조기 경고 시스템 제공

시스템 아키텍처 (전체 구조)



데이터 수집 및 구축 과정

데이터 수집 담당: 이정한

수작업 기반으로 **3일간 집념으로 구축한** 대규모 재무 데이터셋

KIND 크롤링

상장, 상폐기업 목록 실시간 수집



Open DART API

재무제표 데이터 확보



데이터셋 구축

2015~2025 10개년 정형화

정량적 데이터 규모

대상 기업 (상장 / 상폐)

2,766 개 / **354** 개

구축 완료된 파일 수

128,998 개

분석 데이터 총 크기

16.7 GB

▲ 수집 과정의 현실적 제약과 해결

DART API 요청 횟수 제한 문제

일일 호출 제한으로 인한 수집 중단 위기 발생

→ 다수의 API Key를 수동으로 교체하며 72시간 연속 수집

데이터 누락 및 표기 불일치

기업별 재무 항목명 상이 및 공시 누락 데이터 발견

→ 12만 개 파일을 직접 전수 검사하며 수작업 보완

데이터 정형화의 복잡성

JSON/CSV 간의 구조적 결합 난이도 상존

→ 예측 모델에 즉시 학습 가능한 30개 Feature셋 완성

재무비율 기반 입력 데이터 구조 및 문제점

1. 재무비율 30개 입력

성장성

수익성

안정성

활동성

가치평가

총 30개의 핵심 재무비율 피처를 사용하여 기업의 건전성을 다각도로 분석합니다.

#	카테고리	비율명	산출식	18	안정성	비유동자산장기적합률	비유동자산 / 장기차입금
1	성장성	총자산증가율	(기말총자산 - 기초총자산) / 기초총자산 × 100	19	안정성	순운전자본비율	(유동자산 - 유동부채) / 총자산 × 100
2	성장성	유동자산증가율	(기말유동자산 - 기초유동자산) / 기초유동자산 × 100	20	안정성	차입금의존도	(장기+단기차입금+사채) / 총자산 × 100
3	성장성	매출액증가율	(당기매출액 - 전기매출액) / 전기매출액 × 100	21	안정성	현금비율	현금예금 / 유동부채 × 100
4	성장성	순이익증가율	(당기순이익 - 전기순이익) / 전기순이익 × 100	22	안정성	유형자산	유형자산 절대값
5	성장성	영업이익증가율	(당기영업이익 - 전기영업이익) / 전기영업이익 × 100	23	안정성	무형자산	무형자산 절대값
6	수익성	매출액순이익률	순이익 / 매출액 × 100	24	안정성	무형자산상각비	CF에서 추출
7	수익성	매출총이익률	매출총이익 / 매출액 × 100	25	안정성	유형자산상각비	CF에서 추출
8	수익성	자기자본순이익률 (ROE)	순이익 / 자기자본 × 100	26	안정성	감가상각비	유형자산상각비 + 무형자산상각비
9	활동성	매출채권회전율	매출액 / 매출채권	27	가치평가	총자본영업이익률	영업이익 / 총자본 × 100
10	활동성	재고자산회전율	매출원가 / 재고자산	28	가치평가	총자본순이익률	당기순이익 / 총자본 × 100
11	활동성	총자본회전율	매출액 / 총자본	29	가치평가	유보액/납입자본비율	(이익잉여금+자본잉여금) / 납입자본금 × 100
12	활동성	유형자산회전율	매출액 / 총자산	30	가치평가	총자본무지효율	(당기순이익 + 이자비용) / 총자본

기업의 재무 상태를 다각도로 반영

2. 초기 데이터 문제

문제 1: 절대값 왜곡

유형자산, 감가상각비 등 절대값 항목 포함

→ 기업 규모에 따라 값이 폭발적으로 증가

문제 2: 결측치 존재

Feature마다 상이한 결측 데이터 존재

→ 모델 학습 시 데이터의 불안정성 초래

문제 3: 분포 왜곡

값 분포가 한쪽으로 극심하게 치우침 (Long-tail)

→ 이상치 영향으로 인한 모델 성능 저하

원본 재무비율 그대로는 학습에 부적합

입력 구조 재설계 및 전처리 과정

데이터 전처리 담당: 이현지

STEP 1

절대값 항목 비율화

- 유형/무형자산, 감가상각비 등
절대값 지표 대상
- 총자산 대비 비율로 변환

기업 규모 영향 제거 및 비교 가능
성 확보

STEP 2

결측치 대체

- 중앙값(Median) 대체
- 완전 결측 컬럼은 0 처리

이상치 영향 최소화 및 학습 안정
성 확보

STEP 3

로그 변환

$$\text{sign}(x) \cdot \log_{1p}(|x|)$$

- Signed log1p 적용
- 음수 값 속성 유지 가능

분포 왜곡 완화 및 비대칭 분포 보
정

STEP 4

RobustScaler 적용

- 중앙값 + IQR 기반
- 재무 데이터 이상치에 특화


재무 데이터 특성에 최적화된 스케
일링

재무비율 > 비율화 > 결측치 대체 > Log 변환 > Scaling


FINAL FEATURE RESULT
총 30 Features

전처리 결과 검증 (EDA)

정제된 데이터의 특성을 시각적으로 확인하여 분석의 유효성 검증



결측치 분포 분석



정상 vs 상폐기업 분포 비교

모델별 성능 비교 및 분석

모델 학습 담당: 박민서

모델 설명

Logistic Regression

선형 모델로 변수 간의 단순한 관계를 학습

Random Forest

트리 기반 앙상블 모델로 비선형 패턴 학습 가능

XGBoost

부스팅 기반 모델로 데이터의 복잡한 패턴을 정밀 학습

성능 결과

MODEL	PRECISION	RECALL	F1
Logistic	0.1935	0.5000	0.2791
RandomForest	0.3913	0.3750	0.3830
XGBoost	0.4737	0.3750	0.4186

Threshold Tuning 적용

0.5 고정값이 아닌, Validation 데이터 기준 Precision-Recall 균형을 고려한 최적 Threshold를 탐색하여 적용

분석 결과 해석

Logistic Regression

선형 관계만 학습하여 재무 데이터의 복잡한 패턴 반영 한계

→ 낮은 Precision 발생

Random Forest

비선형 학습을 통해 안정적인 성능 확보 가능성 확인

XGBoost (Selected)

부스팅 구조를 통한 복잡한 패턴 학습 역량 발휘

→ Precision + F1 최고 성능

최종 모델 성능 분석 (XGBoost)

전처리 및 구조 개선 이후 XGBoost 모델 성능 대폭 향상

최종 모델 성능 (Test 기준)

Model: XGBoost

Precision 0.4737

Recall 0.3750

F1-score

0.4186

ROC-AUC 0.9049

Confusion Matrix (실제 수치)

		Predicted Label	
		정상(0)	위험(1)
Actual Label	정상(0)	3385 TN 정상 예측 성공	10 FP 오탐지(헛경고)
	위험(1)	15 FN 미탐지(놓침)	9 TP 위험 식별 성공

■ TP: 성공탐지 ■ FN: 위험놓침 ■ FP: 헛경고

Precision: 신뢰 확보

위험 예측 기업 중 47%가 실제 상폐로 판명되어 경고 신뢰성 확보

Recall: 탐지력 집중

실제 위험 기업의 37%를 선제 탐지하였으며, 사각지대 개선 연구 병행 예정

핵심 결론

실무 적용 가능한 식별력을 확보, 향후 데이터 확장을 통한 고도화 추진

향후 개선 및 구현 계획 (Roadmap)

현재 한계를 기반으로 단계적 고도화 및 실전형 리스크 엔진 구현

모델 성능 개선 계획

- ✓ 기업 단위 Group Split 적용: 시계열 데이터 누수 방지 및 일반화 성능 강화
- ✓ Threshold 기준 세분화: 정밀도-재현율 균형 최적화를 위한 구간별 임계값 설정
- ✓ LightGBM / CatBoost 추가 비교: 다양한 부스팅 알고리즘 성능 벤치마킹
- ✓ Hyperparameter 탐색: Bayesian Optimization 기반 최적 조합 도출
- ✓ Feature Importance 최적화: 중요도 기반 변수 선택 및 모델 경량화

데이터 확장 및 입력 고도화

- ✓ 공시 데이터 정형화: DART 비정형 텍스트 기반 주요 위험 키워드 추출
- ✓ 거시경제 변수 결합: 금리, 환율 등 외부 지표와 기업 재무 상태의 상관성 학습
- ✓ 시계열 흐름 반영 강화: 과거 추세 데이터 기반의 동적 피처 엔지니어링
- ✓ 섹터 군집화 기반 학습: 산업별 특성을 반영한 군집별 맞춤형 모델 구축
- ✓ 라벨 구조 추가 검토: 상장폐지 시점 및 유형에 따른 세부 라벨링 정의

구현 일정 로드맵

- 6월 Baseline 재평가 및 전략별 최적 Threshold 비교 검증
- 7월 LGBM/CatBoost 모델 추가 및 하이퍼파라미터 집중 튜닝
- 8월 산업 유사도 기반 섹터 군집화 및 군집별 독립 모델 학습
- 9월 다층 모델 결합을 위한 앙상블 아키텍처 설계 및 구현
- 10월 공시·거시경제 데이터 결합 및 통합 시스템 최종 성능 검증