

1. 프로젝트 제목

섹터 군집 및 양상불 기반 상장폐지 예측 모델

2. 프로젝트의 필요성, 목표 및 기대효과

최근 세계 경제는 코로나19 당시의 저금리 기조에서 벗어나 인플레이션 억제에 위한 급격한 금리 인상 시대로 접어들었다. 이러한 '빅스텝'과 '자이언트 스텝'의 단행은 세계 경기를 급격히 냉각시켰으며, 특히 저금리 환경에서 과도한 부채를 차입해 연명하던 기업들에게 치명적인 재무적 위기를 가져왔다. 경영 위기에 몰린 기업들은 경영권 변동이나 무리한 자금 조달, 시세 조종과 같은 불공정 거래의 유혹에 빠지기 쉬우며, 이는 결국 주가 급락과 거래 정지, 나아가 상장폐지로 이어져 시장에 큰 혼란을 야기했다.

특히 국내 주식시장에서 상장폐지는 투자자에게 회복 불가능한 손실을 입히는 가장 치명적인 사건이다. 그러나 정보력과 분석 능력이 뛰어난 기관 및 외국인 투자자와 달리, 대다수의 개인투자자는 상대적으로 정보 접근성이 떨어져 리스크를 고스란히 떠안는 경우가 빈번하다. 또한 기존의 선행 연구들이 시장 규모가 큰 코스피 시장이나 특정 한계기업만을 대상으로 하는 경우가 많아, 코스닥을 포함한 시장 전체의 위험을 포괄적으로 관리하기에는 한계가 있다. 따라서 복잡한 재무제표와 기업 공시, 거시경제 지표를 결합하여 개인투자자들도 직관적으로 위험을 감지할 수 있는 신뢰도 높은 예측 모형이 필요하다.

본 프로젝트의 핵심 목표는 투자자들이 감수해야 하는 불필요한 위험을 최소화하고 장기적인 투자 성과를 보호하는 데 있다. 이를 위해 본 연구는 코스피와 코스닥 상장사 전체를 대상으로 재무제표 데이터, 기업 공시 정보, 그리고 거시경제 지표를 결합하여 상장 폐지 예측 모델을 구축하고자 한다. 구체적으로는 전통적인 머신러닝 알고리즘부터 하이퍼파라미터를 최적화한 딥러닝 모형까지 폭넓게 활용하여 상장폐지에 실질적인 영향을 미치는 핵심 요인을 규명할 것이다. 또한, 접근성이 낮고 복잡한 재무제표 데이터를 분석하여 투자자들에게 단순한 참고 자료 이상의 '경각심을 주는 핵심 도구'를 제공하는 것을 목표로 한다. 감각이나 추측에 의존하는 투자를 방지하고, 기업의 재무 상태와 경영 성과를 가장 객관적으로 보여주는 데이터를 기반으로 투명한 투자 판단을 지원하는 시스템을 실현하고자 한다.

본 프로젝트를 통해 개발된 예측 모형은 무엇보다 개인투자자를 비롯한 다양한 회계정보 이용자들에게 유용한 조기 경보 시스템 역할을 할 것이다. 높은 수익을 쫓기보다 손실을 최소화하는 리스크 관리 도구를 제공함으로써 건전한 가치투자 문화를 정착시키는 데 기여할 것으로 예측된다.

또한, 기관 및 외국인에게 쏠려 있던 정보 비대칭성을 해소하여 시장의 공정성을 높이고, 기업의 부실 징후를 정확히 예측함으로써 국내 금융 시스템 전반의 안정성을 유지하는 데 도움을 줄 것으로 기대된다. 재무, 공시, 경제 지표를 아우르는 종합적인 분석은 기존 연구의 한계를 넘어 보다 포괄적인 기업 진단을 가능하게 하며, 이는 투자자 보호뿐만 아니라 주식시장의 건강성을 회복하는 중요한 밑거름이 될 것이다.

3. 프로젝트의 내용 및 방법

본 프로젝트는 상장폐지 예측을 위해 데이터 수집부터 최종 판단까지의 전 과정을 자동화·정형화된 파이프라인으로 구성한다. 전체 구현 과정은 다음과 같다.

1. 데이터 수집
2. 데이터 전처리 및 특징 추출
3. 섹터 군집화
4. 예측 모델링 및 앙상블
5. 모델 예측 결합 및 최종 판단

1. 데이터 수집 및 자동화 파이프라인 구축

상장폐지 기업과 정상 기업의 재무적 특성을 비교하기 위해, 한국거래소(KRX) 기업공시채널(KIND)을 활용해 시장·산업별 상장 기업 목록을 수집한다. KIND는 공식 API가 없으므로 Python 기반 웹 크롤링을 통해 기업명과 종목코드를 확보한다.

이후 금융감독원의 Open DART API를 활용해 각 기업의 과거 5~10년간 분기 재무제표 및 공시 데이터를 자동 수집한다. dart-fss 또는 opendartreader 라이브러리를 사용해 수집 효율과 데이터 정합성을 확보하며, 전처리 로직을 포함한 자동화 파이프라인을 구축한다.

- 결측률 50% 이상 특징 제거
- 분기별 변화율(Delta) 파생 변수 생성
- GICS 기반 섹터 매핑(11개 주요 섹터)
- 재무 구조가 특이한 산업 및 예외 기업은 분석 대상에서 제외

2. 시간 기준 라벨링 및 시계열 데이터 구성

데이터 오염과 생존 편향을 방지하기 위해, 기업 단위가 아닌 기준 시점(T) 중심의 시간 기준 라벨링을 적용한다.

- 매 연도 말을 기준 시점 T로 설정하고, 이후 실제 상장폐지 발생 여부에 따라 라벨을 정의
- 이미 상장폐지된 기업의 과거 정상 데이터도 학습에 활용
- 기준 시점 T를 이동시키는 Rolling Time-Window 방식을 적용해 데이터 수를 확장하고 시계열 정합성을 확보

3. S3CE 기반 고도화 전처리

데이터를 전체 시장, 개별 섹터, 섹터 군집의 세 층위로 분리하는 S3CE(Sector Clustering and Ensemble) 전처리 전략을 적용한다.

- Soft Impute를 활용한 결측치 보간
- SMOTE를 통한 클래스 불균형 완화
- 거래정지 시점에 가까운 데이터에 가중치 부여
- 비정형 JSON 데이터를 분석용 정형 테이블로 변환

4. 섹터 군집화

산업군별 상장폐지 원인이 상이하다는 점을 고려해, 재무 구조가 유사한 산업을 군집화한다.

- 자카드 계수를 유사도 척도로 사용하는 응집형 계층적 군집화 적용
- 군집별로 랜덤 포레스트 기반 특징 중요도를 산출해 핵심 재무 변수만 선별

5. 예측 모델링 및 앙상블 전략

시장 공통 신호와 산업군 특화 패턴을 동시에 반영하기 위해 이중 모델 구조를 설계한다.

- 섹터 군집 모델: 군집별 부실 패턴 학습
- 전체 섹터 모델: 시장 전반의 공통 위험 신호 학습

사용 알고리즘

- FNN(MLP): 재무 지표 간 비선형 상호작용 학습
- RF: 노이즈에 강하고 특징 중요도 해석 가능
- ANFIS: 모호한 위험 축적 과정을 퍼지 규칙으로 모델링
- XGBoost / AdaBoost / GBDT: 비선형 경계와 불균형 데이터에 강한 비교·확장 모델

모델은 서로 다른 특성을 가진 알고리즘을 병렬 학습한 뒤 예측 확률을 평균 앙상블한다.

6. 모델 예측 결합 및 최종 판단 로직

상장폐지 예측의 오탐지 비용을 고려해 보수적인 교집합 앙상블을 적용한다.

- 전체 섹터 모델과 섹터 군집 모델이 동시에 위험으로 판단한 기업만 최종 위험 종목으로 선정
- 두 모델의 예측이 임계값 이상으로 일치할 때만 경고 신호를 발생시켜 안정성을 확보

4. 프로젝트 인원 편성 및 역할

본 프로젝트는 전체 파이프라인을 5단계로 구분하고, 각 단계마다 핵심 기능 단위 중심의 역할 분담을 통해 효율적인 협업과 책임 관리를 수행한다.

1단계: 데이터 수집

역할	주요 내용
공시·재무 데이터 수집	KIND 크롤링 및 Open DART API를 통한 재무제표·공시 데이터 자동 수집
시장·비재무 데이터 수집	주가, 거래량, 동전주 여부 등 시장 기반 보조 데이터 확보
데이터 저장 구조	Raw 데이터 저장 구조 설계 및 이후 전처리 단계와의 연계

2단계: 데이터 전처리 및 특징 추출

역할	주요 내용
데이터 정제	결측치·이상치 처리 및 Soft Impute 기반 보간
특징 엔지니어링	분기별 변화율(Δx), 추세 기반 파생 변수 생성
데이터 구성	클래스 불균형(SMOTE) 처리 및 학습용 데이터셋 구성

3단계: 섹터 군집화

역할	주요내용
섹터 유사도 분석	자카드 계수 기반 섹터 간 재무 구조 유사도 계산
군집 생성	응집형 계층적 군집화 수행
군집 검증	군집 결과 시각화 및 경제적 타당성 검토

4단계: 예측 모델링 및 앙상블

역할	주요내용
개별 모델 학습	FNN, RF, ANFIS 기반 전체·군집 모델 학습
확장 모델 비교	XGBoost, Boosting 계열 모델 성능 비교
앙상블 구성	평균 앙상블 및 모델 출력 통합

5단계: 최종 판단 및 결과 도출

역할	주요내용
예측 결합	전체 모델·군집 모델 교집합 기반 위험 종목 선정
안정화 전략	임계값 설정을 통한 오탐지 최소화
결과 시각화	위험 종목 리포트 및 예측 근거 시각화

5. 프로젝트 추진일정

전체 일정 개요

- 기간: 2026년 2월 ~ 2026년 10월

- 구성 원칙

- 전반부: 데이터 파이프라인 안정화
- 중반부: 모델링, 군집화 집중
- 후반부: 앙상블, 검증결과 정리

- 2~3월: 공시·재무·시장 데이터를 자동 수집하는 파이프라인을 구축하고, 원천 데이터의 정합성을 확보한다.
- 3~5월: 결측치 처리, 시계열 변화율 생성 등 핵심 전처리 및 특징 추출을 수행하여 학습 가능한 데이터셋을 완성한다.
- 5~6월: 산업 간 재무 구조 유사도를 기반으로 섹터 군집화를 수행하고, 군집별 핵심 특징을 선별한다.
- 6~8월: 전체 시장 모델과 군집 모델을 병렬적으로 학습하고, 다양한 알고리즘을 결합한 앙상블 구조를 설계한다.
- 8~10월: 교집합 앙상블 기반 최종 판단 로직을 적용하고, 성능 평가 및 결과 시각화를 통해 프로젝트를 마무리한다.

단계	주요 작업	2월	3월	4월	5월	6월	7월	8월	9월	10월
1단계	데이터 수집 파이프라인 구축	■	■							
	KIND / DART 자동화 수집	■	■	■						
2단계	전처리-특징 추출		■	■	■					
	시계열-파생 변수 설계			■	■	■				
3단계	섹터 군집화				■	■				
	군집 검증 및 특징 선택					■	■			
4단계	예측 모델링					■	■	■		
	앙상블 구조 설계						■	■		
5단계	최종 판단 로직							■	■	
	성능 평가 리포트								■	■

6. 참고문헌 (필요시)

1. 김태관, 이상호, 이기훈(2024) 섹터 군집화 및 머신러닝 앙상블 모델 기반의 주식 종목 선택. 데이터베이스연구 제40권 제3호 pp. 86~96
2. 황진경, 송혜령, 유동희(2023) 재무비율과 거시경제 지표 기반 상장폐지 예측모형 개발: 최적화 및 머신러닝 기법 활용. 「인터넷전자상거래연구」 제23권 제4호 pp. 253~271